

Сбор и верификация данных

Общие понятия


Данные - это сведения, показатели, совокупность информации, характеризующие кого-либо или что-либо, и служащие для каких-либо выводов и решений (**общий смысл**)

Данные - пассивная часть ПО или совокупность значений, определенных элементов памяти, преобразование которых осуществляет КОД (с точки зрения **техники**)

Данные - это наблюдение, количественные показатели, описание или результаты исследований (с точки зрения **экономистики**)

ETL (Extract, transform, load)

Извлечение, преобразование, загрузка.




Данные должны быть интегрированы, полными и достоверными.

4 уровня аналитики:

1. Дескриптивная аналитика

Данные о текущем состоянии



посещаемость


выполнение условий

2. Диагностическая аналитика (почему?)


исторические данные, тестирование
гипотезы, эксперимент

3. Прогнозная аналитика

Прогнозирующая, предсказательная, проп-
тирующая, угадывающая (что будет?)



4. Пресекательная аналитика
(что делать?)



Источники и методы сбора данных.

Данные бывают **внутренними** и **внешними**.

Внутренние - Мы определяем состав, структуру, управляем количеством.

Внешние - Мы можем наблюдать и контролировать состав, структуру и количество.

Структурно данные:

• Структурированные данные Таблицы, БД, json, xml

• Не структурированные данные. Источники: документы, текст, медиа

• Потокные данные. Источники: датчики, приборы.

Каким источником и набором данных:

1) Общее. Определяет политику данных и стоимость хранения и обработки.

Data Lake

2) Разнообразие: ⁺бесструктурность, разные форматы и методы обработки

3) Скорость передачи данных. Данные нужны вовремя.

Задачи управления данными:

1) Обогащение данных → добавить источники (генератор или адаптер) или сгенерировать данные или получить данные

2) Очистка данных → удалить дубликаты или переместить в архивацию или деидентификация

Приоритет данных.

ЧУМ, ЛУМ

Высокий приоритет:

• Данные нужны немедленно

- Данные повышают ценность
- Разным задачам и компаниям требуются разные данные

AutoML

- Транзакционные исторические данные
- Средний прирост
- Дополнение уже есть. Новая данных, новые маркет-качество.
- Код обработки данных может использоваться повторно.
- Данные легко доступны.
- Удобный API позволяет собирать данные за разные периоды.

Средний прирост

- Компания уже имеет доступ к дан-ным

- Низкое качество данных
- Необходимы извлечение и парсинг веб-страниц, соц. сетей и др. источников данных
- Низкая вероятность использования данных

Методы сбора данных

- ручной сбор - вручную с каждым источником
- парсинг - HTML, соц. сети
- интеграция - API, готовые datasets,

БА

Типы источников данных

Внутренние	открыт CRM, ERP, MES, ...	готов. логи систем
Внешние	Kaggle, Hugging Face, Git Hub, ...	чужие б.б., сайты с оч.

Риски и затраты:

Если источник внутренний, то мы контроли-

сирцеи и управленим количеством, но бжѣи и количества ограничены. Затраты незначительные

Внешний открытый: масштаб и доступность, но формат и количество. Мы можем только контролировать количество. Затраты средние.

Внешний закрытый: ограниченный доступ, затраты высокие.

Задача с проектированием:

	открытые	закрытые
внутренние	CRM	логи, вебсайты и новостные события
внешние	Kaggle, соц. сети	Публичный API

Источники	+	-	Риски	Затраты	Приоритет
Логи	Структурированность, детальность	Сложность обработки, объем ресурсов	Пропуск событий, неполнота	Средние	Высокий
CRM	Доступность, данные о реальных клиентах	Нет данных о тех, кто не стал клиентом	Устаревание данных (LTV)	Средние	Высокий
Kaggle dataset	Бесплатно, готовая разметка	Не специфично для нашего сервиса	Несоответствие реальности	Низкие	Низкий
Платный API	Чистые данные, легальность	Высокая цена, лимиты запросов	Отключение доступа	Высокие	Средний
Соцсети (Scraping)	Мнения и демография пользователей	Неструктурированность, бан по IP	Юридические риски, блокировки	Высокие	Средний
Потоковые события (Kafka)	Обработка в реальном времени	Сложность инфраструктуры	Потеря данных при сбоях	Высокие	Высокий

Критерии оценки при покупке данных

- 1) Цена $ROI > 50\%$ - возврат инвестиций
 $ROI < 10\%$

$$ROI = \frac{\text{Доходы} - \text{расходы}}{\text{расходы}} \cdot 100\%$$

2) Качество

3) Измеримость

4) Наличие тестовой выборки

5) Актуальность и обновление

6) Надежность источников

7) Безопасность

8) Условия использования

9) Формат

10) Документация

11) Объем

12) Степень детализации

Функции сбора данных

Можно получить качественные данные.

Углубленные данные.


Минимизировать "мусор на входе → мусор на выходе"

Принципы:

- Сильный смысл и контекст
- Незнание изменений
- Необходимость понимания ситуации
- Бюджетный контроль

Функции сбора данных

— процесс, при котором человек собирает, проверяет или изменяет информацию, которую невозможно или сложно корректно получить автоматически. Человек выступает учителем для машины.



Пункты для оценки качества пункта сбора:

- 1) Классификация
- 2) Извлечение информации
- 3) Поиск данных
- 4) Проверка качества

Инструкция

Структура хорошей инструкции

Цель: постановка задачи (что нужно сделать?)

Описание вариантов решений	материал или пример информации основные примеры данных критерии оценки
примеры	что не так / что примеры ошибок

популярные и
старые моменты

Доп. правило: что делать если сомневаешься

Инструкция должна быть краткой и последовательной.

Примеры:

цель: массовые отзывы


Компании: положительный, отрицательный

Пример: мне очень не понравилось. Доставка ужасная

Рекомендация: отрицательный отзыв.

Кружководитель - распределение задач между

очень большим кол-вом живых людей через интернет.



Примеры: Индекс лояльности и качества

+ Скорость
цена
качество

- Качество работы

нужно минимизировать ошибки

источник данных

1) Выборочный контроль

2) Дублирование работы

Решение большинства

взвешенное суждение каппа Козна

$$\frac{P_o - P_e}{1 - P_e} > 0,7$$

P_o - наблюдаемое число совпадений

P_e - ожидаемое число совпадений

Музыкальный цех и разметка данных

1. Сбор и предварительная обработка данных

Процесс начинается с оптимизации базы, которая станет фундаментом для будущего модели.

Источники данных:

- Веб-ресурсы (сайты, соцсети)
- Бизнес-системы (CRM, ERP, MES)
- Опросы, датчики, изображения.

Предварительная очистка. Удаление мусора для экономии ресурсов на этапе разметки.

- Удаление дублей и спама
- Удаление пустых значений и тек. данных
- Фильтрация шума и явных аномалий.

2. Подготовка задания и инструкций.

Качество работы разметчика напрямую

зависит от того, насколько четко поставлена задача (70-80% ошибки возникают из-за неясных инструкций)

Подготовка. Определение формата результатов, формулировка задачи и тех. приведение данных.

Состав идеальной инструкции: цель, объект, результат, правила и алгоритмы, спорные случаи, примеры, контрольный тест.

3. Процесс разметки и контроль качества.

Разметка должна быть четкой, а проверка - многоуровневой.

Инструментарий: понятный интерфейс и беззатяжное дублирование.

Методы контроля: Вязкой тест, коэф. совпадения, зрительный стандарт, аналитика

поведение, аудит.

4. Управление качеством (Feedback Loop)

Процесс постоянно дорабатывается
Формируется рейтинг исполнителя, при
падении рейтинга - бон или переобучение,
если спорных случаев $> 1\%$ - пересмотр
и уточнение инструкции.

5. Человеческий фактор и ошибки

Причины: невнимательность от уста-
лости (рем. - отр. времени работы), непони-
мание задачи из-за инструкции, ситу-
ационные ответы (фривол).

Решение: постоянное корректирование
процесса по основе обратной связи.

Бизнес

> 40% переп. и.и. (интервенции)

небольшие данные (секретована человек, механизмами, системами)

ген. модели (здоровой двойник)

Ошибки в данных:

- 1) Оценки и ошибки ввода
- 2) Ошибки к-тов работы.
- 3) Бой датчиков и в API
- 4) ИИ ЭКО (большой V секретованных данных)

Решение:

- Форматы
- Детекция аномалий
- Заполнение пропусков
- Системы верификации.

Форматы данных: jpeg, png

Audio: mp3, wav

Video: mp4, mkv

Табличные данные:

1) DB, Postgres

2) CSV

3) JSON


} $\begin{pmatrix} [&] \\ [&] \end{pmatrix}$
структурное
хранение

4) Parquet / Clickhouse

[[] [] []]

5) Lance $\begin{matrix} \square & \square \\ \square & \square \end{matrix}$ + Data Version

Ланс аннотации



Z - Score

Если данные соответствуют требованиям.

Биномиальная
распределение.




$$\mu = \frac{1}{n} \cdot \sum_{i=1}^N p_i$$

$$\sigma = \frac{1}{N} \sum_{i=1}^N p_i (p_i - \mu)$$

$$z = \frac{p_i - \mu}{\sigma} > 3 \Rightarrow p_i - \text{аномалия}$$

Нормировать. $\bar{\mu}_i = 0, \bar{\sigma}_i = 1$

$$\frac{p_i - \mu_i}{\sigma_i} = \bar{p}_i; \frac{\bar{\mu}_i}{\bar{\sigma}_i} = 0$$



ненормальное распределение

IQR inter quantile range

Box Plot рисуется так

Разделяющее дерево.




Записки пропусков

1) Записать средний показатель с кодами.

воспроизведением

2) K - NN




3) Систематическая генерация с помощью трансформеров.

4) Специальное значение, кодирующее отсутствующие данные.

Статистические показатели

1) Среднее арифметическое мат. ожидание

$$\{x_i\}_{i=1}^n \quad \mu = \frac{1}{n} \sum_{i=1}^n x_i$$



2) Медиана

50% перцентиль

3) Мода (наиболее часто встречающееся значение)

4) Среднеквадратичное отклонение и дисперсия

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2} \quad MSE \quad \|x_1 - x_2\|$$


$$\frac{1}{n} \sum_{i=1}^n (x_i - \mu) \quad MAE$$

$$X = \{x_i\}_{i=1}^n; \quad Y = \{y_i\}_{i=1}^n$$


Коэффициент Пирсона

$$r \in [-1; 1], \quad r \approx 1$$

$$r \approx -1$$



$$r \approx 0$$



Плечо Сильнейша

Парадокс Сильнейша

A один бубоз

B

Комментарии	Q_1 (зубарь)	Q_2 (амрей)	Сильней
Меньше	15 %	12 %	↙
Сопри	72 %	68 %	↘
Сильнее	35 %	40 %	↗


Методы выявления связи

1) Временная последовательность

A или B были раньше

Если зауженный пещану → ↑ продаж

Если ↑ продаж → зауженный пещану




2) Трансформационный механизм

Есть не линейный мост от A и B.

$$A \rightarrow G(A) = B$$

3) Измерение 3-го квантиля




Визуализация данных.

1) Индекс эффективности краски

$$\text{Data.ink Ratio} = \frac{\text{Число красочных данных}}{\text{Объем всех данных на графике}}$$

2) Индекс достоверности





$$\frac{\Delta \text{Данных на графике}}{\Delta \text{Данных реальн.}} = \text{Lie Score}$$

$$L\$ = \frac{3}{0,06} = 50$$



Эффекты визуализации





Графикс безграницамен:

- 1) Осв. нон. LO
- 2) Min. Data. Inu Ratio
- 3) Меньше 3D
- 4) 1 график - 1 месяц

Дамбонга

- 1) BI система


Yandex Data Lens, Analytics workspace

Fine BI

Логич. написание дамбонга

- 1) Логическим данные SQL/CSV/json/excel
- 2) Data set (все в один текст)

3) Трассировка



4) Дамба

Copilot

LLM $\rightarrow$ python matplotlib
 $\downarrow$
HTML

Бизнес $\rightarrow$ HTML

Язык C и B

- 1) Сценарий
 - 2) SQL code
 - 3) Баз. управление
 - 4) Управление дамбой
 - 5) Управление по заданным правилам
 - 6) Служ. по управлению базисом
 - 7) Описание
 - 8) Компонент
 - 9) Интеграция
 - 10) Управление
- 11) Коммуникация

